

Product Scraper

Kako koristiti alat za scrapanje kataloga proizvođača i kako ga proširiti — novi proizvođači, nova polja, napredna podešavanja.

1. Što je Product Scraper
2. Pokretanje alata
3. Osnovni tok rada — korak po korak
4. Rezultati i gdje ih naći
5. Dodavanje novog proizvođača (bez koda)
6. Praćenje dodatnih polja (custom coverage)
7. Napredno: proizvođač kroz kod (za developere)
8. Ručno dodavanje značenja — ontologija (za developere)
9. Savjeti i najčešći problemi

Što je Product Scraper

Desktop alat koji iz službenih stranica proizvođača automatski skuplja podatke o industrijskim elektro/mehaničkim proizvodima (dimenzije, materijal, napon, struja, certifikati, slike, datasheetovi...). Uneseš listu kataloških brojeva → alat scrapa → dobiješ uređeni **Excel** (i opcionalno **PDT** workbook).

Princip rada

Vrijednost uvijek dolazi iz stvarnog izvora (stranica proizvođača, PDF datasheet, ili dokument koji priloži korisnik). Alat **ne izmišlja** podatke — ako nešto nije pronađeno, polje ostaje prazno, a ne pogodak.

Sve lokalno

Radi na `127.0.0.1:3001`, bez cloud servisa. Nema slanja podataka trećima (osim opcionalnog "reader" fallbacka koji se mora ručno uključiti).

Ulaz / izlaz

Ulaz: CSV/XLSX s kataloškim brojevima. Izlaz: `products.xlsx`, slike, PDF-ovi, CAD datoteke, i po potrebi PDT Excel predložak.

Kako pokrenuti alat

Dvije opcije, ovisno o tome radiš li kao korisnik ili kao developer alata.

Kao korisnik — desktop aplikacija

Pokreni desktop shortcut / `npm run desktop`. Otvara se prozor aplikacije — ništa dodatno nije potrebno, poslužitelj se pokreće u pozadini automatski.

Kao developer — u browseru

`npm run dev` pokreće API i UI zajedno (hot-reload). Ako treba samo API: `npm run server`. Sučelje je dostupno na `http://127.0.0.1:3001` (ili Vite dev port).



Ako `node` / `npm` nisu na PATH-u u terminalu, koristi puni put: `/c/Program Files/nodejs` + `npx`.

Osnovni tok rada — korak po korak

Ovo je put kojim prolaziš za svaki novi "run" (obradu jedne liste kataloških brojeva).

1 Odaberi proizvođača

Padajući izbornik gore lijevo. Ako proizvođač već postoji u listi, samo ga odaberi — ništa dodatno nije potrebno. Ako ne postoji, vidi poglavlje 5.

2 Učitaj CSV ili XLSX s kataloškim brojevima

Povuci datoteku u zonu za upload ili klikni za odabir. Datoteka treba imati jednu kolonu s kataloškim brojevima proizvoda — alat sam pokušava prepoznati koju.

3 Provjeri odabranu kolonu

U pregledu (preview) potvrdi da je "Catalog column" ispravna. Vidljiv je i broj redaka te sva upozorenja (npr. prazni redovi, duplikati).

4 (opcionalno) Priloži dokumente kupca

Ako kupac šalje svoj PDF/Word/Excel/CSV sa specifikacijama, povuci ga u zonu "Customer documents". Podaci iz tih dokumenata **imaju prednost** i prepisuju ono što je scraper pronašao na webu.

5 Odaberi što se generira (Outputs)

Označi kućice: **Excel** (radna tablica), **Images** (slike proizvoda), **PDFs** (datasheetovi/certifikati/priručnici), **CAD** (CAD modeli), **Device links** (CSV samo s URL-ovima). Excel + Images su uobičajeni default.

6 Pokreni run

Klikni Start. Status runa prelazi kroz: *queued* → *running* → *completed* (ili *paused* / *cancelled* / *failed*). Run se može pauzirati i nastaviti (Pause / Resume) ili prekinuti (Cancel) dok traje.

7 Pratite status po retku

Svaki kataloški broj završava kao jedan od tri statusa — vidi pločice ispod. Klik na redak otvara detalje: koji su izvori korišteni, koji atributi pronađeni, dokazi (evidence).

8 Preuzmi rezultate

Kad je run završen: preuzmi generirani Excel, pokreni **Generate PDT / Import to PDT** ako treba PDT workbook, ili otvori "Download run log" za dijagnostiku.

• **Found** — svi ključni podaci pronađeni

• **Partial** — pronađeno dijelom, nešto nedostaje

• **Failed** — stranica/proizvod nije pronađen ili nije parsiran



Klik na pločicu na dashboardu (npr. "Weight", "Material") filtrira listu na redove kojima baš to polje nedostaje ili je pronađeno — korisno za brzu provjeru kvalitete.

Rezultati i gdje ih naći

Svaki run sprema svoje datoteke u zasebnu mapu, organizirano po proizvođaču i po runu:

```
outputs/  
  <Proizvođač>/  
    <run>/  
      excel/          ← products.xlsx (+ PDT ako je generiran)  
      images/         ← slike proizvoda  
      documents/      ← preuzeti PDF-ovi (datasheet/certifikat/manual)  
      cad/            ← CAD modeli  
      links/          ← CSV samo s URL-ovima (Device links)  
      customer-documents/ ← kopija priloženih dokumenata kupca  
      logs/           ← run log (dijagnostika, greške)
```



PDT workbook (opcionalan) generira se zasebno gumbom "Generate PDT" / "Import to PDT" — mapira scrapane podatke na CADENAS PDT predložak ([templates/master_pdt.xlsx](#)), po tipu uređaja. Prije importa možeš pregledati i po potrebi ručno promijeniti raspored po sheetovima.

Dodavanje novog proizvođača

Za većinu novih proizvođača **nije potreban developer** — u sučelju postoji čarobnjak ("Paste URL wizard") koji sam otkriva kako se do proizvoda dolazi preko URL-a. Klikni **New** pored padajućeg izbornika proizvođača.

1 Ime

Upiši puno ime proizvođača (npr. "nVent Hoffman"). Kratko ime (šifra) se generira automatski, po potrebi je promijeni.

2 Website

Zalijepi službenu web stranicu ili čak direktan link na jedan konkretan proizvod ako ga imaš — to čarobnjaku pomaže da odmah pogodi obrazac URL-a.

3 Sample kataloški brojevi

Upiši 2–3 stvarna kataloška broja tog proizvođača, jedan po redu. Koriste se za testiranje obrasca prije spremanja.

4 Auto-detect

Klikni "Auto-detect" — alat pretražuje homepage, sitemap i tražilicu stranice da pronađe obrazac URL-a za pojedini proizvod (npr. `.../product?id={part}`).

5 Test samples

Klikni "Test samples" — alat stvarno otvara stranice za tvoje sample brojeve i provjerava je li pronašao pravi proizvod. **Spremanje je zaključano dok test ne prođe** (minimalno jedan potvrđen proizvod).

Allow distributor fallback (kućica, isključeno po defaultu)

Ako proizvođač nema dovoljno podataka na svojoj stranici, alat može dodatno tražiti kod distributera. Distributerski podaci **nikad ne prepisuju** službene podatke proizvođača — samo popunjavaju praznine. Uključi samo ako je stvarno potrebno.



Advanced mode (prekidač gore desno u editoru proizvođača) otvara sve postavke — rate limit, dodatne fallback izvore, marker pravila za skidanje podataka iz sirovog HTML-a, lokalizirane URL predloške (en/de) itd. Ovo je za finije podešavanje, obično uz pomoć developera.



Ako si ugrađenom (built-in) proizvođaču promijenio postavke i nešto je krenulo po zlu, gumb "**Reset override**" vraća proizvođača na originalne (built-in) postavke.

Praćenje dodatnih polja (Custom coverage)

Dashboard po defaultu prati standardna polja (Weight, Material, Dimensions, Voltage...). Ako želiš na dashboardu posebno pratiti i neko polje specifično za tog proizvođača (npr. "IP Rating"), dodaj custom coverage tile.

Korak	Što upisati
Label	Naziv koji se prikazuje na pločici, npr. <code>IP Rating</code>
Match pattern	Regex (case-insensitive) koji prepoznaje naziv atributa na stranici/dokumentu, npr. <code>ip rating ingress</code>



Obično jednostavne riječi rade bez znanja regexa: `operating temperature`, `thread|connection`. Ovo se podešava u editoru proizvođača (sekcija "Custom coverage") ili po pojedinom runu preko ikone uređivanja na dashboardu — po-run izmjena ne mijenja postavke proizvođača trajno.

Napredno: proizvođač kroz kod DEV

Wizard iz poglavlja 5 pokriva većinu slučajeva. Poseban konektor u kodu treba se pisati samo kad je stranica proizvođača kompleksna: JS-heavy render, skriveni JSON u mreži, tabovi/akordeoni koje treba otvarati klikom, custom login/paywall itd.

Dva mjesta za dirati

Fajl	Svrha
<code>src/server/config/manufacturers.ts</code>	Profil proizvođača — bazni URL-ovi, rate limit, fallback izvori, marker pravila. Isto što wizard sprema, samo kao kod.
<code>src/server/scrapers/<id>.ts</code>	Dedicated konektor — <code>export class <Vendor>Connector implements ManufacturerConnector</code> , s vlastitom <code>scrape()</code> logikom.
<code>src/server/scrapers/index.ts</code>	Registracija — dodaj lazy-load unos u <code>connectorLoaders</code> mapu.

```
// scrapers/index.ts

const connectorLoaders = {

  ...,

  novi_proizvodac: async () => new (await import("../novi_proizvodac.js")).NoviProizvodacConnector()

};
```

Bez dedicated konektora, nepoznati proizvođač automatski koristi `ConfiguredManufacturerConnector` — radi isključivo na temelju URL predložaka iz configa (baš ono što wizard postavlja). Znači: **konektor u kodu je izuzetak, ne pravilo.**



Prije bilo kakve strukturne promjene u kodu, pročitaj `PROJECT_MAP.md` u root-u repozitorija — tamo je puna mapa modula, tokova podataka i pravilo "diraš X → diraj i Y" (npr. nova vrsta uređaja povlači izmjene u `device-type.ts`, `pdt/device-type-profiles.ts` i `pdt/device-sheet-map.ts`).

Prije commita

`npx tsc --noEmit` i `npx vitest run`. Ako je node/npm izvan PATH-a, koristi `/c/Program Files/nodejs` + `npx`.

Ručno dodavanje značenja — ontologija DEV

Razlika prema poglavlju 6: **custom coverage** (bez koda) samo dodaje pločicu na dashboard koja prati je li neki label pronađen. **Ontologija** je dublja — ona uči alat što label *znači*, univerzalno, za sve proizvođače i jezike, i pretvara ga u pravi normalizirani atribut (npr. `ratedVoltage` s brojem i jedinicom, ne samo "postoji/ne postoji"). Zato se ontologija mijenja u kodu, ne u sučelju.

Kad ovo treba

Proizvođač na stranici/PDF-u koristi label koji alat ne prepoznaje (npr. "Nennfrequenz", "rated duty cycle", neki kraticom pisan naziv) pa vrijedna specifikacija ostaje neiskorištena, umjesto da postane atribut poput frequency/voltage/current.

1 Pronađi što je nemapirano

Pokreni `npm run scripts/audit-unmapped-spec-labels.ts` — ide kroz povijest svih runova u `data/scrapper.db` i ispisuje labela koje ontologija ne prepoznaje, rangirane po učestalosti. Ovo je polazna točka, ne pogađanje.

2 Otvori `src/server/scrapers/ontology.ts`

Sve je u jednom nizu `PROPERTY_ONTOLOGY: CanonicalProperty[]`. Svaki unos ima `key` (stabilni ID atributa, npr. `ratedVoltage`), `label`, opcionalni `unitKind` (npr. "voltage" — govori parseru kakav broj/jedinicu da očekuje) i `synonyms` — lista regexa koji prepoznaju taj label na više jezika.

3 Postoji li već svojstvo za to?

Ako da (npr. "rated duty cycle" je varijanta postojećeg `dutyCycle`) — samo dodaj novi regex u njegov `synonyms` niz. Ako label opisuje nešto potpuno novo — dodaj potpuno novi `CanonicalProperty` objekt s vlastitim `key` / `label` / `unitKind` / `synonyms`.

4 Pazi na lažne pogotke (exclude)

Ako novi regex slučajno hvata i nešto što **nije** to svojstvo (npr. "coil" hvata i "coil resistance", ne samo "coil voltage"), dodaj u `exclude` (tekst prije labela) ili `excludeAfter` (tekst poslije labela, za kvalifikatore poput "(Type A/AC operation)").

5 Provjeri i testiraj

Pokreni ponovno audit skriptu da vidiš je li label sišao s liste nemapiranih, te `npm run vitest run` (posebno `tests/ontology.test.ts` ako postoji) da ništa drugo nisi pokvario.

```
// ontology.ts – primjer: dodavanje sinonima postojećem svojstvu
{
  key: "frequency",
  label: "Frequency",
  unitKind: "frequency",
  synonyms: [
```

```

/rated\s+frequency/i,

/nennfrequenz/i,      // ← novi sinonim

...

]

}

```



Za attribute koje ontologija ne uspije pogoditi ni preko sinonima ni preko jedinice, postoji i `technical-attribute-aliases.ts` — ručna lista alias-a s traceable dokazom (`evidenceUrl` / `evidenceLabel`), globalna ili po proizvođaču. Koristi se za rijetke, jednokratne kvirkove koje ne isplati generalizirati u regex; svaki alias mora imati stvaran izvor (link na stranicu/PDF gdje je taj label viđen).



Ne pisati novi regex/parsing "na brzinu" direktno u konektoru pojedinog proizvođača (`scrapers/<vendor>.ts`) za opće značenje atributa — to je jednokratna zakrpa koja se gubi i ne pomaže drugim proizvođačima. Opće značenje ide u `ontology.ts`, parsiranje broja/jedinice u `quantity.ts`, a finalna normalizacija u `normalizer.ts`.

Savjeti i najčešći problemi

Situacija	Što napraviti
Puno redova završava kao Failed	Provjeri je li kataloški broj u ispravnom formatu za tog proizvođača (varijante formata se automatski isprobavaju, ali ne sve). Otvori redak i pogledaj koji su URL-ovi probani.
Polje je prazno, a znam da postoji na stranici	Otvori redak proizvoda → provjeri izvore/dokaze. Možda je label na stranici neobičan i ontologija ga ne prepoznaje — javi developeru da dodaju sinonim (ne treba novi regex po proizvodu).
Kupac je poslao svoj Excel/PDF sa specifikacijama	Priloži ga kao "Customer document" prije pokretanja runa — te vrijednosti automatski prepisuju scrapane.
Run traje jako dugo	Normalno za proizvođače s Playwright renderiranjem (JS-heavy stranice) — rade sporije jer se stranica stvarno otvara u pregledniku. Pauziraj i nastavi po potrebi.
Nešto sam pokvario u postavkama proizvođača	"Reset override" vraća built-in proizvođača na zadane postavke.
Treba mi PDT, a Excel već postoji	Nema potrebe za novim runom — klikni "Generate PDT" / "Import to PDT" na postojećem runu.



Za sve što ovaj vodič ne pokriva (nova vrsta uređaja, promjena PDT predloška, dublja pitanja o arhitekturi) — javi se developeru tima ili pogledaj [docs/ARCHITECTURE.md](#) u repozitoriju.